



Christophe Alcantara
Francine Charest
Serge Agostinelli
(Dir.)

Big Data et visibilité en ligne

Un enjeu pluridisciplinaire de l'économie numérique

Christophe Alcantara, Francine Charest et Serge Agostinelli (Dir.), *Big Data et visibilité en ligne. Un enjeu pluridisciplinaire de l'économie numérique*, Paris, Presses des Mines, Collection Design numérique, 2018.

© Presses des MINES - TRANSVALOR, 2018

60, boulevard Saint-Michel - 75272 Paris Cedex 06 - France

presses@mines-paristech.fr

www.pressesdesmines.com

ISBN : 978-2-35671-507-4

ISSN : 2552-2183

© Photo de couverture : Pixabay

Dépôt légal : 2018

Achevé d'imprimer en 2018 (Paris)

Cette publication a bénéficié du soutien de l'Institut Carnot M.I.N.E.S.

Tous droits de reproduction, de traduction, d'adaptation et d'exécution réservés pour tous les pays.

Big Data et visibilité en ligne

Un enjeu pluridisciplinaire
de l'économie numérique

Collection Design numérique

Sous la direction de Pierre-Michel Riccio

Serge Agostinelli et Nicole Koulayan, *Les écosystèmes numériques*.

Autres titres sous la direction de Pierre-Michel Riccio

Pierre-Emmanuel Mérand, *Le devenir numérique des territoires ruraux*,

Yves Barlette, Daniel Bonnet, Michel Plantié, Pierre-Michel Riccio, *Désordres numériques : incertitude et opportunités*

Yves Barlette, Daniel Bonnet, Michel Plantié, Pierre-Michel Riccio, *Réseaux numériques et performance des entreprises*

Yves Barlette, Daniel Bonnet, Michel Plantié, Pierre-Michel Riccio, *De l'innovation technologique à l'innovation managériale*

Shadia Ramsahye, Pascal Souclier, Pierre-Michel Riccio, *Entre usages et pratiques : la mutation des métiers audiovisuels*

Yves Barlette, Daniel Bonnet, Michel Plantié, Pierre-Michel Riccio, *Impact des réseaux numériques dans les organisations*

Pierre-Michel Riccio, *Technologie et organisations*

Pierre-Michel Riccio, Daniel Bonnet, *TIC et innovation organisationnelle*

Serge Agostinelli, Dominique Augey, Frédéric Laurie, *Entre communautés et mobilité : une approche interdisciplinaire des médias*

Pierre-Michel Riccio, Daniel Bonnet, *Management des technologies organisationnelles*

Sous la direction de :

CHRISTOPHE ALCANTARA, FRANCINE CHAREST

ET SERGE AGOSTINELLI

Big Data et visibilité en ligne

Un enjeu pluridisciplinaire
de l'économie numérique

Introduction

Christophe Alcantara

IDETCOM, Université Toulouse 1 Capitole (France)

Francine Charest

OMSRP, Université Laval de Québec (Canada)

Serge Agostinelli

LAMIA, Université des Antilles (France)

Le colloque scientifique international «*Big Data* et visibilité en ligne, un enjeu pluridisciplinaire de l'économie numérique» proposait d'interroger en novembre 2017 le concept de *Big Data* à travers des entrées multiples : informatique, juridique, gestionnaire et info-com. Le *Big Data* est caractérisé dans la littérature par quatre «V» (Volumétrie, Vitesse, Variété et Valeur). La visibilité des entreprises comme celle des internautes dépend de la maîtrise de cet enjeu car la visibilité est le résultat de l'application de modèles, de choix stratégiques et de tactiques opératoires propres au web. Le résultat affecte les individus et les structures. La visibilité en ligne concerne alors différents domaines académiques et professionnels. Elle interroge particulièrement les algorithmes qui opèrent lors de requêtes sur le web mais aussi les outils qui autorisent les traitements qualitatifs et quantitatifs de données. Comme toute activité numérique génère des traces, c'est une autre piste possible d'investigation pour comprendre cet enjeu. Les communications présentées dans cet ouvrage sont rassemblées autour de quatre axes scientifiques différents et complémentaires. La lecture peut alors se faire de façon thématique. Les travaux publiés reposent pour la plupart sur des études empiriques menées sur des terrains très diversifiés.

En guise d'ouverture, Agostinelli interroge le traitement des données massives et il montre que les modèles tant théoriques que méthodologiques sont encore à construire pour bien appréhender le *Big Data*. Cela est d'autant plus pertinent que selon lui, les outils façonnent notre façon de percevoir le monde. Il propose alors plusieurs pistes de définition et il souligne un changement de paradigme à l'œuvre où l'on passe d'un déterminisme expérimental établi par des lois scientifiques à un déterminisme empirique qui repose sur des probabilités. Cette ouverture se termine par le zoom d'un professionnel du secteur, Pfliger, qui propose un éclairage sur les pratiques actuelles et les technologies propres au concept de *Big Data*.

Le premier axe, intitulé «applications, stockage et exploitation des données» rassemble six communications. Paquelin propose une étude de cas réflexive dans le champ de l'enseignement supérieur. Il interroge le sens et les modalités de la mobilisation des données massives à des fins pédagogiques pour sélectionner et pérenniser le parcours des étudiants. Elisabeth et Sébastien présentent une étude menée dans le champ médical. Leur contribution interroge les moyens par lesquels l'accès à la masse de données médicales produites peut influencer les pratiques de la chaîne des acteurs du secteur. Henry et Stattner, à partir de la diffusion de messages sur Twitter, proposent une méthode pour extraire des données sur la polarité et la subjectivité des messages ainsi que sur la personnalité des utilisateurs. Capelle, Lehmans et Liquette interrogent de leur côté les promesses de l'*open data* dans le champ de l'éducation à partir d'une recherche action menée dans l'académie de Bordeaux et ils soulignent un besoin de médiation sur les données massives et ouvertes dans le but de développer leur réutilisation, notamment en contexte scolaire. Metge et Lamic posent la question du *learning analytics* dans le cadre spécifique de l'université des Antilles. Ils appréhendent l'intégration et l'utilisation de ces derniers comme une solution pertinente pour lutter contre l'exode des étudiants antillais vers la métropole. Enfin, Quillaud, Saglietto (et al.) interrogent le terrain de l'industrie logistique pour montrer que la production de données massives et leur exploitation sont un bouleversement radical, une disruption, des habitudes et pratiques professionnelles de ce secteur d'activité.

Le deuxième axe, appelé «les enjeux juridiques de la visibilité en ligne et du *Big Data*», est constitué de cinq contributions de juristes français et canadiens. Dans un premier temps, Moumouni se positionne dans un cadre international et macrosocial. Il propose une focale sur le droit européen, français, américain et canadien afin de clarifier le concept de *Big Data* et de souligner les enjeux géopolitiques qui se posent à la gouvernance mondiale du *Big Data*. En second lieu, Moritz pose la question d'un rééquilibrage souhaitable entre le consommateur et les acteurs du web en montrant que les mécanismes de certification prévus par l'article 42 du règlement général sur la protection des données peuvent constituer des solutions viables. De façon complémentaire, Eynard part du constat de la marchandisation des données personnelles pour montrer qu'il est nécessaire de rechercher un mode opératoire de régulation «à même de sauvegarder les droits et libertés considérés comme fondamentaux». Lavenue met en lumière un processus de colonisation juridique. Pour lui, le *Big Data* est un avatar du lobby exercé par les GAFAM pour marchander les données personnelles. Enfin cet axe se termine par la contribution de Mouron qui analyse les traces numériques post-mortem à partir de la loi du 07 octobre 2016 pour une république numérique. Il montre que ce dispositif contribue au «développement d'un droit général sur l'identité numérique».

Le troisième axe relève de la visibilité des individus et des organisations. Il est constitué de cinq contributions qui prennent toutes appui sur des études empiriques. Hardy interroge la part visible et invisible en ligne des individus en Chine. À partir d'un cadre théorique qui se réfère dans une large mesure aux travaux de Cardon, l'auteur dénonce l'influence de la visibilité en ligne dans un pays, *a minima* dirigiste, où les classements de visibilité proposés par les algorithmes ont un impact réel sur la perception des individus par le pouvoir. Doran et Lacasse traitent de leur côté la question du *Big Data* dans la perspective de placer la donnée au cœur de la gouvernance à venir des universités à partir du concept de campus universitaire intelligent (*smart campus*). Abbassi présente une étude réalisée au sein d'une organisation marchande qui cherche à définir et organiser l'écosystème web d'une entreprise, objet protéiforme dont le *Big Data* est l'une des composantes. Creton et Kogan traitent la notion de visibilité dans le monde des arts à partir d'un corpus de musiciens de la scène nantaise qui investissent le réseau social Facebook et utilisent des outils issus de traitements de données massives pour optimiser leur visibilité en ligne. Enfin, dans le prolongement des interrogations qui portent sur la visibilité en ligne, Bendinelli et Riccio réalisent une étude de terrain sur la relation entre marques et consommateurs via les réseaux sociaux.

Le quatrième et dernier axe scientifique s'intitule «influence, mesure d'exposition et méthode d'évaluation de la visibilité en ligne». La contribution de Lo Monaco, Poplimont et Metge est d'ordre méthodologique. Ils prennent appui sur la théorie des représentations sociales pour produire une intelligibilité des données obtenues par les outils de *Big Data*. Pascal, Utecht et Alcantara traitent de la notion d'influence en menant une étude fournie sur les «auteurs chevronnés» de Tripadvisor. La quantité d'information publiée sur une telle plateforme nécessite une infomédiation et ils cherchent à apprécier l'impact de notoriété, de crédibilité, voire d'autorité de tels contributeurs en ligne. Enfin, Marrel et Labatut complètent ce travail d'analyse de la visibilité en ligne et de l'influence à travers la communication politique numérique de la maire de Paris en cherchant à mesurer l'écho webmédiatique de celle-ci sur un corpus singulier.

EN GUISE D'OUVERTURE

La compréhension intuitive des données : de Hal à Watson

Serge Agostinelli

Professeur des Universités
LAMIA, Université des Antilles

INTRODUCTION

En 1968, le supercalculateur Hal 9000 gère le vaisseau spatial Discovery One (Clarke 1968). C'est la référence fictionnelle en matière d'intelligence artificielle. Pour la réalité, le programme Eliza fonctionne par simple reconnaissance de formes et substitution des mots-clés dans les phrases produites. Cinquante ans plus tard, Watson d'IBM prend des décisions de tout ordre grâce à des algorithmes de *machine learning*. Watson observe, interprète, évalue, et analyse les données en masse. C'est un service cognitif basé sur le langage naturel qui permet de prendre des décisions à partir des données. Il met à la portée de tous des capacités avancées et encourage les utilisateurs à interagir de façon naturelle avec les données.

Cette facilité apportée à chacun favorise probablement un *a priori* qui laisse penser que la théorie n'est plus nécessaire à la compréhension et au traitement des données massives. Certains annoncent même la fin de la science telle que nous la connaissons, car «*avec suffisamment de données, les chiffres parlent d'eux-mêmes*»¹. Selon ce point de vue, le glissement d'intérêt de la causalité vers la corrélation et l'exhaustivité des données, permettent désormais de laisser parler les données comme si elles agissaient de manière autonome (Cukier, 2014). Ce point de vue sera peut-être un axiome demain, mais la prudence nous pousse à penser que les modèles tant théoriques que méthodologiques sont encore à construire. En effet, la notion de *Big Data* (BD) n'est pas monolithique (Sugimoto, 2016) et le contexte va jouer un rôle essentiel dans sa compréhension.

En 2020², 44 000 milliards de Go des données seront produites par 50 milliards d'objets connectés et les ordinateurs suivront avec des systèmes informatiques capables de traiter un milliard de milliards de calculs par seconde. Des *exaflops* de

1 Anderson, publié le 23/06/08, consulté le 23/01/18 www.wired.com/2008/06/pb-theory/

2 Etudes IDC 2014, france.emc.com/campaign/observatoire-de-la-donnee/index.htm

données qu'il faudra stocker, analyser et interpréter alors que les spécialistes estiment que *l'internet des objets* double la taille de l'univers numérique tous les deux ans. Les données en masse sont donc omniprésentes, mais hétérogènes. Elles peuvent être utilisées pour compter des clics et le trafic sur les pages Web ; trouver des modèles en bourse ; suivre les préférences des consommateurs ; identifier les corrélations linguistiques dans les grands corpus de textes... Ceci pourrait expliquer que le *BD* ne soit pas uniquement une question de taille, de vitesse ou de virtualisation.

Autant dire que le traitement des données en masse relève d'une multitude de problèmes à la fois scientifique et de terrain. Rien de neuf pourrait-on dire, sauf qu'aujourd'hui, les outils de recueil et de traitement relèvent systématiquement du domaine des outils informatiques et on sait depuis bien longtemps que les outils façonnent notre façon d'appréhender le monde (Simondon, 1969 ; Rabardel, 1995 ; Agostinelli, 2009) et les paradigmes qui confèrent leur spécificité aux activités d'analyse.

Ce que nous venons d'avancer ne remet pas en cause les courants théoriques en faveur d'une approche basée sur les données. Bien au contraire, ceci pointe la nécessité d'une réflexion sur les rôles que jouent les outils de stockage, de traitement et d'analyse sur la théorie et dans quelle mesure la compréhension intuitive des données remet en question ou modifie ces rôles. D'autant que *l'intuition*, ici *opératoire*, est une construction progressivement élaborée au cours des expériences passées jusqu'à atteindre une connaissance immédiate et non raisonnée d'un ensemble de moyens, de procédés, de règles intéressant une activité. L'intuition est donc une construction et le débat ne devrait-il pas se faire entre outils et données, et non entre théorie et données ? Sans modèle théorique ni connaissance spécifique, comment définir le *BD* ?

1. BIG DATA : VIEUX PROBLÈME OU RÉVOLUTION EN MARCHÉ ?

Ce qu'il y a de surprenant avec les avancées technologiques, c'est que les médias en font immédiatement un concept qui va inévitablement révolutionner notre futur. Cet engouement pour les technologies n'est pas nouveau et repose probablement sur les liens qui existent entre le progrès technique et le progrès humain. Toutefois, si la technologie est capable de construire des outils sans cesse en progrès : par l'extension des domaines d'action ; par l'évolution de leurs capacités prédictives et explicatives ; par la mise en cohérence des domaines entre eux ; il ne faut oublier pas que la roue et la poulie n'étaient pas des applications de connaissances scientifiques théoriques. Elles ont été à la fois le produit d'une activité humaine et de pratiques sociales, mais aussi des *creusets* de la connaissance humaine socialement partagée à un moment donné (Agostinelli, 2009). Dès lors, opposer les outils, les données et les théories n'a pas de sens (Agostinelli, 2013).

Dire qu'avec suffisamment de données, les chiffres parlent d'eux-mêmes, revient à dire qu'un schéma vaut mille mots ou qu'un prototype vaut mille images ; oui, pour qui sait lire le schéma ou connaît les formes et les fonctions du prototype. Bien sûr, plus l'individu devient expert d'un domaine professionnel, plus il parvient à voir et à comprendre intuitivement, donc sans recourir à l'application de règles, des ensembles significatifs et à y associer les actions, décisions ou stratégies appropriées (cf. Agostinelli, 2010). S'il pense pouvoir se passer des modèles et des théories, c'est qu'il met en œuvre des connaissances compilées en routine lorsqu'il rencontre une situation d'une même classe de problèmes. Ces routines donnent alors une forme d'intuition à ses actions et ses connaissances sont donc étroitement liées à sa compréhension des données.

Là aussi, rien de neuf si on se réfère aux traces laissées par les internautes. L'analyse de contenu dans l'étude des représentations sociales, l'analyse de corpus en linguistique, les analyses des données textuelles regroupent les méthodes qui permettent de mettre en évidence l'information essentielle contenue dans un texte ou dans un ensemble de textes. Watson est annoncé comme une technologie cognitive qui peut penser comme un humain. Outil multifonction, il peut analyser et interpréter tous types de données, y compris le texte non structuré, les images, l'audio et la vidéo. Il peut fournir des recommandations personnalisées en comprenant la personnalité, le ton et l'émotion d'un utilisateur. Il peut aussi utiliser l'apprentissage automatique pour développer l'expertise d'autres applications ou d'autres systèmes. Issu du croisement des sciences cognitives et de l'informatique, Watson cherche à reproduire l'ensemble des processus mentaux liés à la construction de connaissances. Il est l'aboutissement de l'informatique cognitive qui cherche à doter les systèmes informatiques de capacités intellectuelles comparables à celles des êtres humains.

Pour faire court, si l'utilisateur n'a plus besoin de modèles et de théories pour utiliser les outils et traiter les données, c'est que les modèles de compréhension humains ont été intégrés à l'outil. Ce qui n'existait pas dans des outils plus anciens de traitement mathématique ou statistique qui ne disposaient que des modèles de leur discipline. Les analyses et interprétations sont laissées aux utilisateurs en fonction de leurs besoins. Cette intégration est issue de la formalisation informatique des connaissances liées à l'usage des outils et au dépassement de la notion d'artefact définie par Norman (1993). Dans les outils traditionnels sont inscrites les intentionnalités culturelles et les activités productrices associées. Pour revenir à la poulie, si elle est bien un *creuset* de la connaissance qui associe un modèle de mécanique élémentaire et des pratiques, elle est construite dans un matériau qui ne contient que ses propres propriétés : le bois, le fer, le plastique... Le travail d'anticipation des usages possibles est fait par l'utilisateur. Aujourd'hui, une *poulie augmentée* conduirait à avoir un outil qui a une forme de connaissance en propre et des possibilités cognitives du traitement des situations et des données.

2. INFORMATIQUE COGNITIVE ET TRAITEMENT DES DONNÉES

Une approche cognitive du traitement des données se fonde sur la capacité à acquérir de l'information et à la transmettre en contexte. Si le traitement de l'information remonte à l'origine de l'informatique, il ne faut pas oublier que d'autres Sciences ont participé à la compréhension du contexte même si aujourd'hui, l'informatique les a évidemment adaptées à ses propres finalités.

2.1. Les origines

L'approche contextuelle de la cognition trouve ses origines dans la Psychologie et l'Anthropologie cognitive. Le terme *contexte* renvoie à la situation immédiate dans laquelle l'activité cognitive se déploie, mais aussi, à la culture globale dans laquelle elle prend place. La cognition ne réside pas en propre dans la tête d'un individu sous la forme de connaissances abstraites et transportables d'une situation à une autre. Elle relève de l'interaction entre les individus et elle est partagée avec les objets et les outils qui se trouvent dans l'environnement (Vygotsky, 1978). Ces outils sont des médiateurs des activités et des processus mentaux des individus. L'activité est alors un système à trois niveaux d'interactions, non réductibles l'un à l'autre, entre le sujet et l'objet (Leontiev, 1976 ; Galpérine, 1980) : le niveau des activités ; le niveau des actions ; le niveau des opérations. Ces niveaux inter-reliés ont largement été mis en œuvre pour la compréhension des liens qui relient les outils, les connaissances et le contexte, entre le sujet individuel et la structure sociétale (Engeström, 1999). On peut aussi associer les travaux de Norman (1993, 2002) sur les *artefacts cognitifs* ou les travaux des anthropologues cognitivistes (Lave, 1988 ; Lave et Wenger, 1991) qui ont étudié les performances cognitives d'individus en contexte de résolution de problèmes du quotidien.

Ces travaux montrent l'importance du croisement des modèles issus de la psychologie cognitive et la conception des systèmes homme-machine. Ils donnent naissance au terme d'*ingénierie cognitive* (Norman 1986) qui englobe les modèles à l'intersection des utilisateurs, de la technologie et du travail.

2.2. L'informatique

L'informatique s'intéresse aux modèles de l'approche contextuelle de la cognition par les mathématiques, par les démarches logico-déductives et expérimentales des sciences exactes. De leur côté, l'IA et les Sc. Cognitives ont largement formalisé les approches des Sc. Humaines telles que la Psychologie Cognitive pour la formalisation des processus mentaux et l'Ergonomie pour l'analyse d'une situation à informatiser. En effet, les théories, les modèles et les techniques

de ces disciplines ont particulièrement contribué à l'essor de l'Informatique et aujourd'hui des objets connectés.

Depuis le modèle du processeur humain qui permet de mettre en relation la perception de l'interface et la performance (Card, et al., 1986) ou le lien direct entre variable psychologique et objet informatique (Normand, 1986), l'extraction et acquisition des connaissances ont dépassé le modèle expert. Le modèle expert sépare le programme avec ses capacités générales de raisonnement et d'inférence et les connaissances spécifiques au domaine de connaissances, représentées le plus souvent sous la forme d'affirmations et de règles (SI conditions ALORS conclusions).

Aujourd'hui, l'informatique cognitive est fondée sur des modèles symboliques, sur des modèles connexionnistes et sur une ingénierie des connaissances qui englobe la conception d'applications d'aide intelligente à l'utilisateur (De Calvary et al., 2012). Pour cela, le *traitement automatique des données* (TAD) passe par un processus de représentation (des données) formalisé et modélisé sous forme d'un ensemble structuré de *relations logico-mathématiques* (RLM). C'est l'aspect calculatoire qui donne un premier sens aux données. Bien sûr, le traitement et l'interprétation possible seront différents si l'aspect calculatoire est effectué par un calculateur, un ordinateur traditionnel, des ordinateurs à architecture parallèle ou en réseaux de neurones. L'évolution des architectures est particulièrement liée aux études sur la structure et le fonctionnement du cerveau humain ce qui donne un aspect intuitif à l'utilisation des outils. Dans les applications issues des nouvelles architectures, la dimension cognitive articule d'ailleurs l'espace des fonctions (ou noyau fonctionnel) et l'espace de l'interaction (ou interface homme-machine) de manière à respecter les représentations et usages des utilisateurs. C'est l'ingénierie des connaissances développées par l'IA qui doit être conforme aux schémas mentaux de l'utilisateur et trouve sa logique dans l'interface homme-machine.

À partir de ces deux concepts fondamentaux (TAD et RLM) ont été élaborés d'autres concepts plus opérationnels. Le stockage des données est passé des bases de données, le plus souvent structurées et relationnelles, aux *infocentres* qui ont centralisé toutes les données structurées en *silos* et les ont regroupés en *entrepôt*. Les relations entre les bases permettent de traiter le détail de l'information avec la granularité la plus faible. Elles permettent aussi de leur appliquer le plus de dimensions possibles pour maximiser les possibilités d'agrégations et de recherches. Toutefois, la hiérarchie et les dimensions donnent une verticalité à la structure et dès lors, les données sont difficiles à réorganiser.

Avec les systèmes arborescents comme Hadoop³ on stocke de gros volumes de données à structures variables, mais surtout sans connaître à l'avance comment

³ *Hadoop Distributed File System* permet de stocker de très gros volumes de données sur un grand nombre de machines.

les données vont être utilisées et analysées. Ce système de stockage n'a pas de structure *a priori*, elle est créée au moment de l'analyse. Ainsi apparaît le concept opératoire de *lac de données* (Dorian, 1999) avec lequel les données sont conservées sur le même plan. Toutefois, l'automatisation produit un flot toujours croissant de données, alimentant un océan si vaste que nous ne pouvons que regarder *monter la marée* Dorian (1999), et incapable de saisir les connaissances qui *nagent* dans ce vaste océan. Traditionnellement, la *pêche* dans les données relève de l'analyse statistique, mais cette analyse aurait la même efficacité qu'un pêcheur muni d'une canne à bouchon pour rassembler tous les poissons de l'océan.

Les entreprises ont besoin de moyens puissants et plus efficaces pour moissonner, explorer et identifier les données de l'océan et ramener la récolte. Aujourd'hui, il existe trois outils pour la récolte : (a) la modélisation des données qui révèle chaque *poisson* ; (b) l'arpentage des données qui relève du *chercheur de poissons* qui examine l'état de l'océan ; (c) et la préparation des données qui *aplanit l'eau et enlève les vagues* afin que le *poisson* soit clairement visible et facilement attiré.

Cette métaphore autour de l'océan montre que le *BD* en tant qu'objet d'étude scientifique interroge autant qu'il échappe, à l'image de sa masse, de sa fluidité, à la fois insaisissable et insondable à travers ses multiples facettes. Au-delà de son aspect possédant une masse et un volume définis, une forme variable et des éléments relativement mobiles les uns par rapport aux autres, le *BD* révèle les pratiques liées à l'information et à ces mécanismes de contrôle qui s'élaborent pour son partage ou sa gestion.

2.3. Le Big Data : un concept qu'il reste à définir

Le terme de *BD* est polymorphe, il désigne autant la rapidité de renouvellement des données issues d'objets spécifiques (connectés) ; la quantité de données générées ; celle à recueillir ; la multiplicité des formats des données à stocker ; les méthodes formelles ou non de traitement ; et enfin, ce qui n'est pas des moindres, servir à quelque chose.

Actuellement nous sommes comme Mickey⁴, après avoir emprunté le chapeau magique du sorcier Yensid. Il est débordé par un balai qu'il a lui-même ensorcelé pour qu'il aille chercher de l'eau à sa place et qui s'est multiplié en grand nombre. Après la métaphore du pêcheur qui portait notre attention sur les données et le contexte, cette métaphore montre pour nous, l'intérêt qu'il faut porter aux outils (la canne ou les seaux). Il est vrai que plusieurs siècles de méthode scientifique ont aguerri la recherche aux processus par lesquels on acquiert les données, à

4 Fantasia (1940), Walt Disney Productions.

l'attention portée aux résultats factuels, aux techniques expérimentales, aux problèmes, aux hypothèses à valider ou réfuter, aux théories et aux concepts qui jouent un rôle essentiel dans la conception et l'organisation des observations et des expériences. Toutefois, le réductionnisme nécessairement appliqué change aujourd'hui avec la nature même des terrains et de leurs données observables.

Suivant ce point de vue, ce serait l'opérationnalisation (la mise en outil) des données qui permettrait le passage entre les champs d'activité et de recherche voisins, mais à visées différentes. Le *BD* deviendrait alors un *concept-en-contexte* qui se construit en fonction d'une analyse finalisée. Le traitement est alors lié aux finalités et indépendant de la nature des objets. Lié aux finalités, le *BD* est alors un ensemble de propriétés pour agir, pour résoudre des problèmes avec comme limite la transparence en terme citoyen (cf. PROXEM⁵; Cardon, 2015) et d'objectivité en terme scientifique (Boyd et Crawford, 2012).

2.4. Comment définir le Big Data ?

La gestion des données ou des informations a toujours été liée au développement de l'informatique (Devakunchari, 2014). Cette gestion étant corrélée à la puissance des machines du moment: nous sommes passés de l'*explosion d'information* (Marron et al., 1967) des années 70 au *suivi des flux d'information* (de Sola Pool, 1983) des années 80 qui analyse les moyens de communication. En 76, le stockage numérique devient plus rentable que le papier (Morris et Truskowski, 2003). Les années 90 amorcent la problématique actuelle: le rythme et le volume du flux d'information saturent les réseaux, les dispositifs de stockage et les systèmes de recherche, mais aussi la capacité humaine de compréhension (Denning, 1990). En 97, les octets peuvent tout stocker, aucune information ne doit être rejetée, mais une information spécifique n'est jamais regardée par un être humain (Lesk, 1997). Le flux de données sur Internet dépasse les autres moyens de communication en 2002, (Coffman et al., 1998). Le terme de *BD* apparaît en 99 pour qualifier la quantité massive de données qu'autorisent des machines, mais, déjà, cette quantité pose un problème, car *le but de l'informatique est la perspicacité et non les chiffres* (Bryson et al., 1999).

Depuis ces années, la nécessité de traiter un flux croissant de données a permis la mise au point d'une large variété de techniques et de technologies pour agréger, manipuler, analyser et visualiser des données dynamiques: les *bases de données de traitement massivement parallèle*, l'exploration de données, les *systèmes de fichiers distribués*, les *bases de données distribuées*, les plateformes *cloud computing*, etc. (Devakunchari, 2014).

5 www.proxem.com. www.compol.media/algorithmes-ont-avenir-politique

Dès lors, comment définir le *BD*? Peut-être par un *pseudo-concept essentiellement opératoire*. La compréhension de l'évolution du *BD* résulterait donc d'une construction intentionnelle, effectuée par le chercheur. Le concept avec lequel on donne du sens aux données n'est pas plus qu'une propriété, une fonction ou une relation que l'on attribue à notre réalité. Il n'est donc pas étonnant que les chercheurs qui s'intéressent au *BD* appartiennent à des champs différents tout en pensant travailler sur la même chose (cf. Agostinelli, 2012). Aujourd'hui, plusieurs perspectives de définition sont possibles pour caractériser le *BD* (Ekbja et al., 2015):

- *Un changement objectif et quantitatif dans la taille des données*. C'est une définition centrée sur l'objet des *BD*. Cette perspective est centrée sur le produit (*product-oriented perspective*).
- *Une évolution significative de la capacité à analyser les données et à en tirer parti*. Il est ici question des processus informatiques d'analyse mis en œuvre pour analyser les données. Elle est centrée sur les perspectives (*process-oriented perspective*) et met l'accent sur les innovations qui permettent de penser que le *BD* est une avancée technologique dans l'analyse des données.
- *Le problème cognitif que pose le développement des mégadonnées* aux chercheurs. Les mégadonnées sont définies, non pas par leur objet, ni par les processus impliqués, mais par les avantages qu'elles représentent par rapport aux capacités d'analyse des êtres humains.
- *Les répercussions sociales*. Les enjeux de la visibilité en ligne et du *BD*; la visibilité des individus et des organisations; l'influence, la mesure d'exposition et les méthodes d'évaluation de la visibilité en ligne.

Le *BD* est bien un concept qu'il reste à définir en fonction des finalités. Un concept qui se forge en surmontant un obstacle qui est lui-même surdéterminé; ici, c'est la représentation que l'on a du *BD*. L'important est donc maintenant d'en comprendre le rôle par rapport à la genèse des connaissances produites et à leur assimilation. Ces représentations qui semblent faire obstacle aujourd'hui sont pour nous, issues des sciences expérimentales qui nous ont formés aux approches empiriques de l'observation. Dans ce cas, l'interprétation des données arrive après l'expérience qui est conduite sans idée *a priori*. Avec le *BD*, les relations entre théorie et expérience sont renversées par une modélisation mathématique *a priori*. Nous changeons de paradigme, puisque d'un déterminisme expérimental établi par des lois scientifiques nous passons à un déterminisme empirique établi par des probabilités.

CONCLUSION

Le *BD* est notre capacité à traiter un volume croissant de données. Les applications ne sont pas une révolution en soi, car la masse de données a toujours été traitée avec la technologie disponible à un moment donné. Dès lors, pourquoi pense-t-on aujourd'hui que les chiffres parlent d'eux-mêmes?

La culture informatique poussée par les fictions et la réalité a modifié notre vie quotidienne et notre regard sur l'évolution humaine. L'écart entre l'homme et la machine est de plus en plus réduit. Il devient même inutile de travailler sur la communication homme-machine puisque les machines sont aujourd'hui capables de comprendre le langage humain et s'expriment avec humour et empathie dans un langage compris de tous. Ainsi, faire glisser cette transparence aux données et laisser croire que les chiffres parlent d'eux-mêmes semble cohérent. D'autant, que l'utilisation des applications analytiques semble relever de quelques connaissances intuitives, celles qui se forment du premier et du plus simple regard.

Avec le *BD*, les utilisateurs sont un peu comme des enfants qui apprendraient les objets concrets des mathématiques: les chiffres avant les nombres abstraits avec leurs rapports et leurs lois; les procédures opératoires avant les propriétés. En fait, ils apprennent à se passer des modèles pour traiter intuitivement les chiffres par des calculs mentaux et c'est bien des années plus tard qu'ils apprendront à raisonner rigoureusement ou de façon analytique.

La technologie est particulièrement bien adaptée à cette démarche inverse de genèse des connaissances et les modèles à construire sont de deux ordres:

- les *modèles analytiques* qui mettent à profit une capacité de traitement pour comprendre les corrélations et les prédictions. On est alors dans le domaine du business intelligence et des *algorithmes prédictifs*.
- les *modèles de l'informatique cognitive* qui autorisent la création de systèmes intelligents et apprenants qui vont seconder l'humain dans des tâches de réflexion, de recherche et d'analyse complexes afin de lui suggérer des options crédibles et opérationnelles. Ici on est davantage dans le domaine de l'intelligence artificielle et entre autres, des *algorithmes créatifs*.

Pour finir, rappelons le rôle essentiel de ces deux types d'algorithme dans l'écriture de la série à succès sur les arcanes de Washington (*House of cards*⁶, 2013). Netflix a largement insisté sur les spécificités de son modèle et sur ses méthodes innovantes, dont le recours aux algorithmes. De la fiction à la réalité...

6 House of Cards est une série télévisée américaine. [fr.wikipedia.org/wiki/House_of_Cards_\(série_télévisée_2013\)](http://fr.wikipedia.org/wiki/House_of_Cards_(série_télévisée_2013)) www.nytimes.com/2013/02/25/business/media/for-house-of-cards-using-big-data-to-guarantee-its-popularity.html

BIBLIOGRAPHIE

- Agostinelli, S., & Metge, M. (2013). Y a-t-il une solution de continuité entre théorie et pratique ? *Etudes de communication*, 40, 43-58.
- Agostinelli, S. (2012). Connaissance : pseudo-concept partiellement opératoire, *Etudes de communication*, 39, 65-73.
- Agostinelli, S. (2010). La pratique comme obstacle épistémologique, *Education Sciences & Society*, (1), 1, 53-64.
- Agostinelli, S. (2009). Comment penser la médiation inscrite dans les outils et leurs dispositifs : une approche par le système artefactuel, *Distances & Savoirs*, (7), 4, 355-376.
- Boyd, D., & Crawford, K. (2012). Six provocations à propos des *Big Data*. In, P. Mounier (dir.). *Une introduction aux humanités numériques* (pp.197-219). Marseille : OpenEdition Press. En ligne [<http://www.internetactu.net/2011/09/23/big-data-la-necessite-d-un-debat/>]. consulté le 12/09/16.
- Bryson, S., Kenwright, D., Cox, M., Ellsworth, D., & Haimes, R. (1999). Visually exploring gigabyte data sets in real time, *ACM* (42), 8, 82-90 [https://www.researchgate.net/publication/220421093_Visually_Exploring_Gigabyte_Data_Sets_in_Real_Time] consulté le 10/11/16.
- Card, S.K., Moran, T.P., & Newell, A. (1986). The model human processor: An engineering model of human performance. In K. R. Boff, L. Kaufman, & J. P. Thomas (Eds.), *Handbook of perception and human performance*, 2, Cognitive Processes and Performance, 1-35.
- Cardon, D. (2015). *À quoi rêvent les algorithmes. Nos vies à l'heure des Big Data*. Paris : Seuil.
- Clarke, A.C. (1968). *2001 l'odyssée de l'espace*. Paris : J'ai Lu, coll. «Science-fiction», 1992.
- Coffman, K.G. & Odlyzko, A. (1998). The size and growth rate of the Internet. *Firstmonday* (3), 10, [<http://firstmonday.org/ojs/index.php/fm/article/view/620/541>] consulté le 23/09/16.
- Cukier, K., & Mayer-Schonberger, V. (2014). *Big Data, la révolution des données est en marche*. Paris : Robert Laffont.

- De Calvary G., Delot, T., Sedes, F., et Tigli JY.(2012). *Informatique et intelligence ambiante: des capteurs aux applications. Traité Informatique et Systèmes d'Information, IC2*. Paris: Lavoisier.
- de Sola Pool, I. (1983). Tracking the flow of information, *Science* (221), 4611, 609-613.
- Denning, P.J. (1990). *Saving all the bits. RLACS Technical Report TR 90.44*, 11p. [<https://ntrs.nasa.gov/archive/nasa/casi.ntrs.nasa.gov/19910023503.pdf>]. consulté le 09/03/17.
- Devakunchari, R. (2014). Analysis on Big Data over the years. *International Journal of Scientific and Research Publications*, (4), 1, [<http://www.ijsrp.org/research-paper-0114/ijsrp-p2573.pdf>]. consulté le 10/09/16.
- Dorian, P. (1999). *Data preparation for data mining*. San Francisco: Morgan Kaufmann Publishers, Inc. ebook [<http://hfs1.duytan.edu.vn/upload/ebooks/3836.pdf>].
- Engeström, Y., Reigio, M., & Raija-Leena, P. (1999). *Perspectives on activity theory*. New York: Cambridge University press.
- Ekbia, H.R., & al. (2015). Big Data, bigger dilemmas: a critical review. *Journal of the Association for Information Science and Technology*, 66, 8, 1523-1545. En ligne: [<https://arxiv.org/pdf/1509.00909.pdf>] consulté le 8/10/16.
- Galpérine, P., I.,(1980). Essai sur la formation par étapes des actions et des concepts. In Talyzina, N.F. (ed.). *De l'enseignement programmé à la programmation des connaissances* (pp. 167-183). Lille: P.U.F. Lille.
- Hutchins, E. (1995). *Cognition in the wild*. New york: Cambridge, MIT Press.
- Kohavi, R., Rothleder, N.J., & Simoudis, E. (2002). Trends in business analytics, *ACM*, (45), 8, 45-48 [<http://robotics.stanford.edu/~ronnyk/cacmEmergingTrendsInBI.pdf>] consulté le 21/01/17.
- Leontiev, A.N. (1974). The problem of activity in psychology. *Journal of Russian & East European Psychology*, (13), 2, 4-33, en ligne le 12/2014, [<http://www.tandfonline.com/doi/abs/10.2753/RPO1061-040513024>] consulté le 23/03/15.
- Lesk, M. (1997). How much information is there in the world? <https://courses.cs.washington.edu/courses/cse590s/03au/lesk.pdf> consulté le 11/09/16.
- Marron, B.A., & de Maine, P.A.D (1967). *Automatic data compression, ACM*, (10), 11, 711-715.

- Morris, R.J.T., & Truskowski, B.J. (2003). The evolution of storage systems, *IBM Systems Journal* (42), 2, 205-217.
- Norman, D. (2002, 2013). *The design of everyday things*. New York : Basic Books.
- Norman, D. (1993). Les artefacts cognitifs. In B., Conein, N., Dodier, L., Thevenot (Eds), *Les objets dans l'action, Raisons Pratiques*, 4, 15-34.
- Norman, D. (1986). Cognitive engineering. In D. A. Norman & S. W. Draper (Eds.), *User-centered system design* (pp. 31-61). Mahwah, NJ: Erlbaum.
- Norman, D. (1983) Some observations on mental models. In, D. Gentner et A. L. Stevens (eds.) *Mental models*, (pp. 7-14). Hillsdale (NJ) : Lawrence Erlbaum Associates.
- Rabardel, P. (1995). *Les hommes et les technologies. Approche cognitive des instruments contemporains*. Paris: Armand Colin.
- Simondon, G. (1969). *Du mode d'existence des objets techniques*. Paris : Aubier-Montaigne.
- Sugimoto, C.R., Ekbia, H.R., & Mattioli, M. (2016, dir.). *Big Data is not a monolith*. Cambridge, Massachusetts : The MIT Press.
- Vygotsky, L. (1978). *Mind in Society. The development of higher psychological processes*. Cambridge MA : Harvard University Press.

Big Data, zoom sur les pratiques professionnelles actuelles

Franck Pflieger

Professionnel - Société Galactus

INTRODUCTION

Si les débats autour des Big Data et de l'Internet des objets ne sont pas nouveaux, ils occupent le devant de la scène. À mesure que la connectivité mobile, la technologie des capteurs et le *cloud computing* s'installent dans notre quotidien, nous devons tous réfléchir de manière proactive, particuliers comme entreprises, aux données que nous créons et à la nécessité de leur trouver un espace de stockage adapté. Il est de plus en plus urgent de trouver des modèles de stockage sûrs permettant un accès en temps réel à une quantité massive de données.

Le volume mondial de données numériques va exploser d'ici 2020, notamment à cause de l'internet des objets et de leurs milliards de capteurs. L'internet des objets contribuera «à doubler la taille de l'univers numérique tous les 2 ans, lequel devrait peser 44 000 milliards de gigaoctets en 2020, soit 10 fois plus qu'en 2013»¹. L'internet des objets est alimenté par plusieurs milliards d'éléments du quotidien, comme les capteurs de vitesse intégrés aux chaussures de sport ou encore les systèmes d'analyse du trafic routier. Ils portent chacun un identifiant unique pour enregistrer, consigner et recevoir automatiquement des données sur le réseau internet.

International Data Corporatio (IDC) ne dénombre actuellement pas moins de 200 milliards de dispositifs ou d'objets capables de se connecter à internet, dont 7 % (soit 14 milliards) communiquent déjà via internet et produisent 2 % des données numériques mondiales. Mais d'ici à 2020, le nombre des objets effectivement connectés devrait atteindre 32 milliards et représenter 10 % du volume total de données générées, assure le cabinet IDC. Et si actuellement, 60 % des données numériques sont issues des marchés matures, «le rapport devrait s'inverser d'ici à 2020», où les pays émergents deviendront les principaux producteurs de données.

¹ Rapport du géant américain du stockage de données EMC et du cabinet de recherche IDC
<https://france.emc.com/about/news/press/2014/20140409.htm>

Pour illustrer ces chiffres, le rapport explique que «le volume annuel de données que produit chaque foyer tiendrait dans 65 iPhones de 32 gigaoctets actuellement, contre 318 en 2020». L'internet des objets va aussi contribuer à augmenter la masse de données numériques exploitables, c'est-à-dire analysables.

Selon le rapport, «en 2013, seules 22 % des données numériques étaient exploitables et 5 % seulement d'entre elles ont été analysées, laissant un vaste trou noir dans l'univers numérique». L'expansion de l'Internet des objets devrait porter «à 35 % la proportion des données exploitables». Il restera aux entreprises à les analyser et à en faire bon usage car «de tels volumes représentent un défi gigantesque, aussi bien au niveau de la gestion, du stockage, de la monétisation et de la protection des données».

1. BUSINESS INTELLIGENCE VERSUS BIG DATA : DE L'INFORMATION À L'INTELLIGENCE

1.1. Deux méthodologies d'analyse différentes

Explorons davantage et plus en profondeur la donnée en introduisant de nouvelles dimensions d'analyse : la détection d'événements, la chronologie des événements dans la collecte des informations, le laps de temps entre les événements ou encore les situations ou les contextes pouvant qualifier les événements intervenus.

La démonstration peut se faire par l'exemple :

- 1^{er} cas : un consommateur regarde une publicité, le lendemain, il visite le site web, deux jours plus tard il appelle un conseiller et le jour suivant il réalise un achat.
- 2^e cas : un consommateur achète un produit, le même jour il visite le site web, puis trois mois plus tard il appelle un conseiller et le mois suivant il regarde la publicité.

Ces deux cas nous montrent la nécessité de comprendre les événements ainsi que la séquence. Même si dans ces deux exemples le client a acheté le même produit, les analyses de l'expérience client et de son parcours sont radicalement différentes.

Prenons maintenant le cas d'un client qui s'adresse à un conseiller d'un service après-vente.

- 1^{er} cas : il visite le site web deux fois dans la journée et en fin de journée il appelle un conseiller.

- 2^e cas : Il visite deux fois le site web dans la journée et trouve la réponse à sa question sans entrer en contact.

1.2. Une interprétation des données différente

L'interprétation des informations sera différente même si dans les deux cas le client a obtenu la bonne réponse à sa question.

Dans ces deux exemples, on peut facilement mesurer la différence en Business Intelligence et Big Data. Ainsi, dans le premier exemple, le marketing met en place des séquences précises pour capturer et enfermer le client dans un parcours défini suivant des règles métiers. Le client volatile, spontané, hybride et indécis casse en permanence les règles, les parcours préétablis et les processus marketing entrant et sortant.

Pour comprendre son comportement, il va falloir déstructurer l'information et la traiter en masse avec une approche orientée question. En effet, les technologies du Big Data permettent de stocker les mêmes données, mais dans des contextes différents, en appliquant des traitements distincts et des séries d'algorithmes différenciées et ceci pour traiter plusieurs problématiques simultanément (NoSql et autres technologies adaptées, graphes, etc.).

On peut également lancer des opérations d'apprentissage sur les données sans avoir d'idées préconçues ainsi que des phases d'observation pour détecter les fameux signaux faibles (information partielle ou fragmentaire fournie par l'environnement). Ainsi, l'ensemble de l'information, les degrés de personnalisation ou les types de recommandation collectés devront pouvoir être reproduits pour être modélisés, donc industrialisés, à grande échelle. La connaissance obtenue inférera la stratégie, les organisations, les hommes et les processus de l'entreprise.

1.3. Pas de lien direct à établir entre BI et Big Data

Il n'y a pas de lien direct à établir entre BI et Big Data. Les techniques d'analyse sont radicalement différentes, pratiquées avec des savoir-faire et des technologies nouvelles. Le nouveau paradigme est en rupture avec les modes de pensée en cours et tend à révolutionner l'approche même de l'analyse de données.

La question se situe donc bien au-delà du débat technologique autour des bases de données SQL, no SQL, en colonne, en mémoire et toute autre variante. L'intérêt du Big Data réside moins dans les sujets traités que dans la façon d'appréhender et de résoudre les problèmes dans des domaines transverses

(marketing, logistique, gestion du risque...) ou dans des domaines spécialisés (santé, énergie, distribution...). C'est le cœur du challenge du Big Data : connaître l'activité humaine, comprendre son contexte, établir les relations entre les données d'activité pour fournir, à un instant donné, un service en temps réel individualisé et personnalisé.

Pour preuve qu'il n'y a pas à avoir de débat autour du fait que l'un doit disparaître au profit de l'autre, les GARTNER's MAGIC QUADRANT². Ces analyses présentent de façon évidente que les deux techniques d'analyse font l'objet d'investissement important chez les éditeurs.



Tableau 1: EDITEURS de logiciels proposant des solutions BI

Tableau 1 : Ce tableau montre que des enseignes aussi prestigieuses et importantes que Microsoft, IBM, SAP, SaleForce, etc. croient et investissent encore dans le développement de solution Business Intelligent (BI). Il est donc déplacé de vouloir entretenir le débat que le Big Data va supplanter le BI. Il s'agit de deux approches différentes mais complémentaires, voir le tableau suivant.

2 <https://blog.censio.fr/bi/magic-quadrant-bi-2017/> <https://rapidminer.com/resource/gartner-magic-quadrant-data-science-platforms/>

Table des matières

INTRODUCTION	7
<i>Christophe Alcantara, Francine Charest, Serge Agostinelli</i>	
EN GUISE D'OUVERTURE	11
LA COMPRÉHENSION INTUITIVE DES DONNÉES : DE HAL À WATSON.....	13
<i>Serge Agostinelli</i>	
Introduction	13
1. Big Data : vieux problème ou révolution en marche ?	14
2. Informatique cognitive et traitement des données	16
Conclusion.....	21
Bibliographie.....	22
BIG DATA, ZOOM SUR LES PRATIQUES PROFESSIONNELLES ACTUELLES.....	25
<i>Franck Pflieger</i>	
Introduction	25
1. Business Intelligence versus Big Data : de l'information à l'intelligence.....	26
2. Les dix grandes tendances du Big Data	29
Conclusion.....	33
AXE 1 : APPLICATIONS, STOCKAGE ET EXPLOITATION DES DONNÉES.....	35
CHAPITRE 1 - LES DONNÉES MASSIVES : ENJEUX ET DÉFIS POUR LA RÉUSSITE ÉTUDIANTE	37
<i>Didier Paquelin</i>	
1. Un enseignement supérieur face à de multiples évolutions quantitatives et qualitatives	37
2. Le modèle universitaire présentiel en évolution	39
3. Des données massives au learning analytics.....	41
4. Enjeux d'un usage raisonné des données massives	46
Conclusion.....	48
Bibliographie.....	48

CHAPITRE 2 - PROGRAMMES DE MÉDICALISATION DES SYSTÈMES D'INFORMATION EN MÉDECINE, CHIRURGIE, OBSTÉTRIQUE ET ODONTOLOGIE : L'APPORT DE LA FOUILLE DE DONNÉES.....51

Elisabeth Erol, Nathalie Sébastien

Introduction.....	51
1. Les enjeux de l'hôpital public et singulièrement de l'hôpital public en Martinique....	52
2. Établissement public de santé et fouille de données.....	54
3. Tout savoir pour enfin pouvoir.....	57
Conclusion.....	58
Bibliographie.....	58

CHAPITRE 3 - COMPORTEMENT DE DIFFUSION SUR LES MÉDIAS SOCIAUX À TRAVERS LE PRISME DE LA QUALITÉ ET DE LA NEUTRALITÉ61

D. Henry, E. Stattner

Introduction.....	61
1. État de l'art.....	62
2. Méthodologie.....	63
3. Exploration des données	65
4. Étude de la diffusion à travers la personnalité et la neutralité	68
5. Discussion.....	73
Conclusion et perspectives.....	74
Bibliographie.....	75

CHAPITRE 4 - DE LA VISIBILITÉ À LA MÉDIATION : L'OPEN DATA ET SES USAGES EN ÉDUCATION77

Camille Capelle, Anne Lehmans, Vincent Liquète

Introduction.....	77
1. Stratégies de mise en visibilité des données et obstacles à la réutilisation	78
2. Médiation et médiatisation des données en éducation	82
3. Mutualisation des activités pédagogiques autour des données ouvertes.....	84
Conclusion.....	85
Bibliographie.....	86

CHAPITRE 5 - *LEARNING ANALYTICS* : QUELLES PERSPECTIVES POUR L'UNIVERSITÉ DES ANTILLES ?.....89

Marielle Agostinelli et Nicolas Lamic

Introduction.....	89
-------------------	----

1. Position du problème.....	90
2. Un point d'entrée pour recueillir des données : le learning analytics.....	91
3. Du learning analytic au Système d'Information longitudinal : l'information mobile.....	97
Conclusion.....	98
Bibliographie.....	99

CHAPITRE 6 - TECHNOLOGIES LOGISTIQUES DISRUPTIVES : UN ÉCLAIRAGE PAR LA DIGITISATION ET LA DIGITALISATION.....	103
--	-----

Alban Quillaud, Laurence Saglietto, Dominique Fernandez Bonet, Gilles Paché

Introduction.....	103
1. Control towers.....	105
2. Business spheres.....	107
3. Supply chain cockpit.....	108
4. Solutions de cloud fédératif.....	110
Discussion et conclusion.....	111
Bibliographie.....	112

AXE 2 : LES ENJEUX JURIDIQUES DE LA VISIBILITÉ EN LIGNE.....	115
--	-----

CHAPITRE 7 - LA GOUVERNANCE MONDIALE DU BIG DATA : PROBLÈMES JURIDIQUES ET ENJEUX GÉOPOLITIQUES.....	117
---	-----

Charles Moumouni

Introduction.....	117
1. Le contexte multidimensionnel du Big Data.....	118
2. Les problèmes juridiques du Big Data du secteur public : la surveillance et la sécurité.....	120
3. Les problèmes juridiques du Big Data du secteur privé.....	122
4. Gouvernance mondiale et enjeux géopolitiques.....	124
Conclusion.....	126
Bibliographie.....	127
Jurisprudence.....	130

CHAPITRE 8 - BIG DATA : ENJEUX DE PROTECTION DES DONNÉES À CARACTÈRE PERSONNEL ET MÉCANISMES DE CERTIFICATION.....	131
---	-----

Marcel Moritz

Introduction.....	131
-------------------	-----

1. Un constat : la place limitée accordée aux consommateurs face aux pratiques du Big Data	132
2. Une perspective : la certification, outil potentiel d'autonomisation de l'utilisateur	135
Conclusion.....	140
Bibliographie.....	140

CHAPITRE 9 - LA PERSONNE AU CŒUR DES BIG DATA 141

Jessica Eynard

Introduction.....	141
1. Les libertés individuelles à l'épreuve des Big Data	142
2. La recherche d'un mode de régulation adapté	146
Conclusion.....	151
Bibliographie.....	152

CHAPITRE 10 - ANALYSE D'UN PROCESSUS DE COLONISATION JURIDIQUE : LE BIG DATA ET LE PROBLÈME DE LA LOCALISATION DES DONNÉES 155

Jean-Jacques Lavenue

Introduction.....	155
1. Big Data et localisation des données.....	156
2. Impérialisme juridique et réaction à la colonisation par le droit	161
Bibliographie.....	166

CHAPITRE 11 - LA VISIBILITÉ EN LIGNE DES MORTS, NOUVEL OBJET DU DROIT SUR L'IDENTITÉ NUMÉRIQUE 167

Philippe Mouron

Introduction.....	167
1. Une tension historique des droits de la personnalité à l'appréhension post-mortem des données	169
2. L'appréhension nouvelle des traces numériques des défunts par le droit des données personnelles.....	173
Bibliographie.....	177

AXE 3 : DE LA VISIBILITÉ DES INDIVIDUS ET DES ORGANISATIONS 179

CHAPITRE 12 - INVISIBLE ET VISIBLE ? LA PART SOCIALE DE L'INDIVIDU EN LIGNE EN CHINE 181

Mylène Hardy

Introduction.....	181
-------------------	-----

1. La visibilité : une question politique ?	182
2. Le jeu de la visibilité	183
3. La visibilité de l'invisible : la part sociale du moi en Chine	185
Conclusion : vers l'impossibilité de l'invisibilité.....	189
Bibliographie.....	189

CHAPITRE 13 - GOUVERNANCE UNIVERSITAIRE, DONNÉES MASSIVES ET VIE PRIVÉE.....	193
---	-----

Marie-Andrée Doran et Nicole Lacasse

Introduction.....	193
1. Les données massives accélèrent la transformation numérique des universités....	194
2. Vers des campus universitaires intelligents.....	195
3. L'intelligence artificielle : plus de possibilités et plus de responsabilités	198
Pour conclure, quelques pistes de réflexion	205
Bibliographie.....	206

CHAPITRE 14 - LES TECHNOLOGIES BIG DATA IMPOSENT DE NOUVELLES NORMES SOCIALES : VISIBILITÉ ET TEMPORALITÉ.....	211
---	-----

Ghislaine Abbassi

Introduction.....	211
1. Big Data, instrument d'influence et de notoriété	212
2. La dimension relationnelle du Big Data : cadre de recherche.....	214
Conclusion.....	217
Bibliographie.....	218

CHAPITRE 15 - DE L'INVISIBLE AU VISIBLE, PRATIQUE DE LA PUBLICITÉ CIBLÉE SUR FACEBOOK PAR DES MUSICIENS ORDINAIRES NANTAIS	221
---	-----

Caroline Creton et Anne-France Kogan

Introduction.....	221
1. De l'invisibilité à la visibilité sur Facebook	222
2. Pratiques et représentations de la visibilité sur Facebook.....	223
Conclusion.....	226
Bibliographie.....	227

CHAPITRE 16 - LA RELATION ENTRE MARQUES ET CONSOMMATEURS VIA LES RÉSEAUX SOCIAUX : UNE APPROCHE ÉMOTIONNELLE	229
---	-----

Marion Bendinelli et Pierre-Michel Riccio

Introduction.....	229
1. L'éthique.....	231
2. L'authenticité	234
3. La confiance	236
Conclusion.....	239
Bibliographie	239

AXE 4 : INFLUENCE, MESURE D'EXPOSITION ET MÉTHODE D'ÉVALUATION DE LA VISIBILITÉ EN LIGNE..... 241

CHAPITRE 17 - ÉTUDIER LES REPRÉSENTATIONS SOCIALES À PARTIR DE GRANDS ÉCHANTILLONS 243

Grégory Lo-Monaco, Christine Poplimont et Marielle Metge-Agostinelli

Introduction.....	243
1. La théorie des représentations sociales	245
2. Représentations sociales, positions sociales et « Big Data »	248
Bibliographie.....	251

CHAPITRE 18 - ANALYSE DES PLATEFORMES EN LIGNE : E-RÉPUTATION ET INTERACTIONS NUMÉRIQUES. ÉTUDE SUR LES « AUTEURS CHEVRONNÉS » DE TRIPADVISOR..... 255

Catherine Pascal, Véronique Utecht, Christophe Alcantara

Introduction.....	255
1. TripAdvisor® : une certaine vision du partage révélatrice d'une stratégie de E-réputation organisationnelle	256
2. « Les auteurs chevronnés », analyse quantitative et qualitative d'une participation ambiguë	258
3. E-réputation et arbitrages : du Big Data à l'usage des internautes. Sont-ils vraiment captifs ?	265
Conclusion : des lois, des normes, de la formation pour plus d'éthique ?	267
Bibliographie.....	268

CHAPITRE 19 - LA VISIBILITÉ POLITIQUE EN LIGNE DE LA MAIRE DE PARIS : CONTRIBUTION À LA MESURE DE L'ÉCHO WEB-MÉDIATIQUE D'ANNE HIDALGO..... 271

Vincent Labatut et Guillaume Marrel

Introduction.....	271
1. À quoi ressemble l'écho Web-médiatique de l'activité d'un·e élu·e ?	272
2. Dispositifs de fouille : l'inaccessibilité des médias sociaux.....	274

3. Fragilité et pertinence des résultats	278
4. Une semaine de travail de la maire de Paris sur le Web.....	280
5. Agenda et écho Web-médiatique : une analyse comparative des contenus	283
Conclusion.....	285
Bibliographie.....	285
FINALEMENT, C'EST QUOI LE BIG DATA ?	287
<i>Serge Agostinelli, Francine Charest, Christophe Alcantara</i>	

En 2020, 35 % des données numériques seront produites par 212 milliards d'objets connectés. 44 000 milliards de Go seront générés par ces objets et les systèmes informatiques devront être capables de stocker, d'analyser et d'interpréter ces données massives (Big Data).

Aujourd'hui déjà, la visibilité des entreprises comme celle des internautes dépend très largement de la maîtrise et de la compréhension du Big Data, caractérisé par les 4 V (volumétrie, vélocité, variété et valeur). Sans compter que les enjeux sont multiples et impliquent des domaines divers : informatique, juridique, communication et gestion.

Cette visibilité, voulue ou induite, est le résultat de l'application de modèles, de choix stratégiques et de tactiques opératoires spécifiques au web. Sa part « invisible » est sollicitée à travers les algorithmes opérant lors de requêtes sur les moteurs de recherche, mais aussi à travers des outils qui autorisent les traitements qualitatifs et quantitatifs des données. Ces activités numériques génèrent des traces, des données de masse qui sont un enjeu économique pour les entreprises digitales et une question de colonisation numérique pour les internautes.

La visibilité sur le web et le traitement automatisé de données de masse s'imposent à tous et ne peuvent être interrogés que par des entrées disciplinaires multiples et complémentaires. C'est l'objet de cet ouvrage qui rassemble des communications qui reposent principalement sur des études empiriques et qui représentent autant de chemins pour interroger le concept de Big Data et sa réalité plurielle.

Christophe Alcantara est maître de conférences en Sciences de l'Information et de la Communication, chercheur à l'Institut de Droit de l'espace, des territoires, de la culture et de la communication (IDETCOM), Université Toulouse 1 Capitole. Ses travaux de recherches s'articulent autour de la notion d'e-réputation, d'identité numérique et de traces digitales.

Francine Charest est professeure agrégée au département d'information et de communication de l'Université Laval de Québec, Canada. Elle est la directrice générale de l'observatoire des médias sociaux en relation publique (OMSRP), centre de recherche qu'elle a mis sur pied en 2010, après avoir pratiqué les relations publiques pendant près de 20 ans.

Serge Agostinelli est professeur d'informatique à l'université des Antilles. Ses recherches portent sur les aspects innovants qui mobilisent le numérique pour développer de nouveaux produits ou services. Il travaille particulièrement sur l'informatique mobile et embarquée de l'internet des objets.